Adrián Pabón Mendoza

Barranquilla, Colombia | adrianpabonmendoza@gmail.com | +57 323 225 7331
LinkedIn: linkedin.com/in/adrianpabonmendoza | Portafolio: adrianpabonmendoza.com/es

Perfil objetivo

Ingeniero Senior de IA (LLMs, RAG & Agentes de IA) | **AWS Certified Solutions Architect – Associate** | Ingeniero Electrónico (Cum Laude) | Python, Java, FastAPI, Docker, Kubernetes, Terraform, AWS/Azure/OCI

Resumen profesional

Ingeniero Senior de Datos e IA llevando sistemas LLM, RAG y agénticos a producción desde 2024. Certificado AWS Solutions Architect – Associate. Construyo arquitecturas agénticas y pipelines RAG sobre bases vectoriales (pgvector, Pinecone, OpenSearch), y evalúo aplicaciones LLM con datasets propios y LLM-as-a-judge. Escalé NAIA de un piloto de 500 usuarios a más de 13,000 usuarios con LLMs de OpenAI, Redis y Microsoft Graph/Azure. Construí un pipeline agéntico que migra stored procedures a microservicios en Java, reduciendo la documentación de cada migración de **2 días a 2 horas**. Despliego en AWS con arquitecturas serverless y event-driven, Docker, Kubernetes y Terraform.

Habilidades

LLMs y agentes: OpenAI, Amazon Bedrock, LangChain, LangGraph, Hugging Face Transformers, orquestación multi-agente, tool-calling, enrutamiento, prompt engineering.
RAG y búsqueda vectorial: embeddings, chunking, recuperación, reranking; pgvector, Pinecone, ChromaDB, FAISS, OpenSearch, Bedrock Knowledge Bases.
Evaluación de LLMs: datasets de evaluación propios, LLM-as-a-judge, métricas de alucinación y relevancia de respuestas, iteración de prompts.
Backend y migraciones: Python, Java, FastAPI/Flask, APIs REST, Redis, SQL, arquitectura hexagonal, migración de stored procedures a microservicios.
Datos: pipelines de datos, modelado de datos en DynamoDB, PostgreSQL, MongoDB, Databricks.
Cloud y DevOps: AWS (Lambda, Step Functions, Bedrock, SageMaker, DynamoDB, EventBridge, API Gateway, Cognito, EC2/S3/RDS), Terraform (IaC), Docker, Kubernetes (escalado de pods y configuración de despliegues), Git, Azure, Oracle Cloud, IBM Cloud.
ML: PyTorch, scikit-learn, fine-tuning.

Experiencia

nyxn — Remoto, Colombia
Ingeniero Senior de Datos e IA — *Feb 2026 – Actualidad*

- Construí una arquitectura agéntica que migra stored procedures core de banca a microservicios en Java 25 con arquitectura hexagonal: análisis del SP y sus dependencias, migración de la lógica y generación de adapters, modelos y utilidades.
- Reduje el tiempo de documentación técnica de las migraciones de SP (Sonar, Prisma, Veracode, pruebas unitarias) de **2 días a 2 horas**.
- Diseñé y orquesté un producto serverless y event-driven en AWS para hacer seguimiento de los roles abiertos en la compañía (Lambda, DynamoDB, EventBridge, S3, Bedrock, API Gateway, Cognito, SES), con infraestructura como código en **Terraform**.
- Construí los pipelines de datos del producto y diseñé su modelo de datos en DynamoDB.

Optimize IT SAS — Barranquilla, Colombia
Especialista de Producto IA / Ingeniero de IA — *Jul 2024 – Feb 2026*

- Entregué una API LLM/RAG con embeddings + búsqueda vectorial, iterando la estrategia de chunking, las plantillas de prompt y los parámetros de recuperación para mejorar respuestas fundamentadas en flujos internos.
- Mejoré la detección de robos en micro-mercados con Visión por Computador, reduciendo en **80 %** el tiempo de revisión manual de cámaras.
- Entrené y evalué modelos de ML para casos de uso en producción (clasificación/regresión), monitoreando métricas clave **(F1, precision, recall, MAE)** y validando con conjuntos hold-out.
- Automaticé flujos de respaldo de bases de datos en OCI (programación, validación, notificaciones) con funciones serverless, mejorando confiabilidad y trazabilidad y reduciendo la intervención manual.

Universidad del Norte — Barranquilla, Colombia
Investigador y Desarrollador de IA — *Ene 2024 – Nov 2025*

- Reduje el tiempo de respuesta administrativa de horas/días a **3–5 segundos** desplegando NAIA (más de 13,000 usuarios), habilitando el autoservicio para consultas rutinarias.

- Diseñé un monolito modular que integra LLMs de OpenAI, estado en Redis y servicios externos vía Azure; implementé acceso seguro mediante Microsoft Graph API (correo/calendario/autenticación).
- Implementé pipelines RAG (chunking, embeddings, recuperación, reranking cuando aplica) y definí conjuntos de evaluación para reducir alucinaciones y mejorar la relevancia de las respuestas.

Proyectos destacados

Agente de IA para Call Center Médico *2026*

Agentes de voz inteligentes para mejorar la atención al cliente en un laboratorio clínico.

- Ejecuté campañas salientes para un call center médico.
- Implementé lógica de **Tool-Calling** para validar citas y resultados de laboratorio en tiempo real, conectando el agente directamente a las bases de datos del centro médico.
- Impacto: **50 %** menos tiempo de los agentes en llamadas rutinarias, liberándolos para interacciones de mayor valor.

NAIA — Nimble Artificial Intelligence Assistant *2024–2025*

Enlace al portafolio | Asistente multi-rol con LLM/RAG e integraciones.

- Arquitectura: LLMs de OpenAI + Redis + servicios de Azure + integración con Microsoft Graph API.
- Escala: más de 13,000 usuarios; definición de flujos operativos y monitoreo para uso en producción.
- Impacto: respuestas conversacionales en **3–5 segundos** (línea base de la arquitectura web).

Detección de Robos (Visión por Computador) *2024*

Pipeline productivo de visión por computador para seguridad en micro-mercados.

- Datos: curación y etiquetado de datasets; entrenamiento/validación de modelos con métricas de CV **(mAP/F1)** y evaluación hold-out.
- Impacto: **80 %** menos tiempo de revisión manual de cámaras.

Publicaciones e investigación

- **NAIA: A Robust AI Framework for Academic Assistance** — *Systems* (2025).
- **Architectures for AI-Powered Virtual Assistants** — *IEEE TEMSCON LATAM* (2025).
- **NAIA: A Multi-Technology Virtual Assistant** — *IEEE Access* (2025).
- **Itinerary Assignment Optimization** — *IEEE COLCOM* (2024).

Educación

Universidad del Norte Barranquilla, Colombia

Ingeniería Electrónica (Cum Laude) *2020 – 2025*

Certificaciones y reconocimientos

- **AWS Certified Solutions Architect – Associate** — Amazon Web Services (Oct 2026 – Oct 2029) | Verificar en Credly
- **Databricks Fundamentals** (2025) | **NVIDIA: Applications of AI for Anomaly Detection** (2025) | **NVIDIA: Generative AI with Diffusion Models** (2025)
- **Conferencista:** Cátedra Europa 2024 ("Computer Vision: A World of Possibilities"). | **Reconocimiento:** Mejor Proyecto de Ciencias (Colciencias, 2019).

Idiomas

Español (Nativo) | Inglés (Profesional / C1)